Retrasos de entrega y satisfacción del cliente en Olist

Reporte técnico · Carlos Daniel Torres Pillado · Datos: Brazilian E-Commerce Public Dataset by Olist (2016–2018) · Código: github.com/cdtorrespi/olist-late-delivery-prediction

1. Resumen

Pregunta: ¿podemos detectar al momento de la compra qué pedidos llegarán tarde, para ajustar la fecha prometida o priorizar su envío y así evitar reseñas negativas?

- Los pedidos que no llegan a tiempo promedian **2.3 estrellas contra 4.3** de los puntuales. Los retrasos explican unas **4,000 reseñas negativas adicionales, el 31%** de todas las del periodo.
- La señal más fuerte es el **colchón del plazo**: los días prometidos divididos entre lo que tardó la ruta (estado del vendedor a estado del cliente) en los últimos 90 días.
- Una regla que revisa el 10% de pedidos con el colchón más corto captura el **29.4%** de los retrasos en un periodo de prueba fuera de muestra (abr-ago 2018), casi 3 veces el azar. La regresión logística y el gradient boosting quedan unos 3.5 puntos abajo, con diferencia significativa.
- **Recomendación:** una alerta diaria con umbral móvil para el equipo de logística, y una prueba A/B de un colchón mínimo de 1.3 veces en la fecha prometida, que habría rescatado el 23% de los pedidos tardíos.

2. Datos y modelo relacional

Los 9 CSV (99,441 pedidos) se cargaron a PostgreSQL 16 y se organizaron en un modelo dimensional: dos tablas de hechos, una por pedido y otra por artículo, que comparten las dimensiones de cliente, vendedor, producto y fecha. Las decisiones principales fueron:

- **Objetivo.** Un pedido está "no a tiempo" si se entregó después del día prometido. La fecha estimada no tiene hora, así que entregar el mismo día cuenta como a tiempo. Los 1,097 pedidos enviados que nunca registraron entrega también cuentan: al corte de los datos todos habían pasado su fecha prometida.
- **Calidad.** Los códigos postales de clientes y vendedores venían sin ceros a la izquierda. Al normalizarlos con LPAD, los clientes sin coordenadas bajaron de 24,266 a 280.
- **Ventana de análisis.** Compras de enero de 2017 a agosto de 2018. Los meses anteriores y posteriores están incompletos. Quedan 97,300 pedidos con resultado conocido, de los cuales 7.8% no llegó a tiempo.

3. Hallazgos

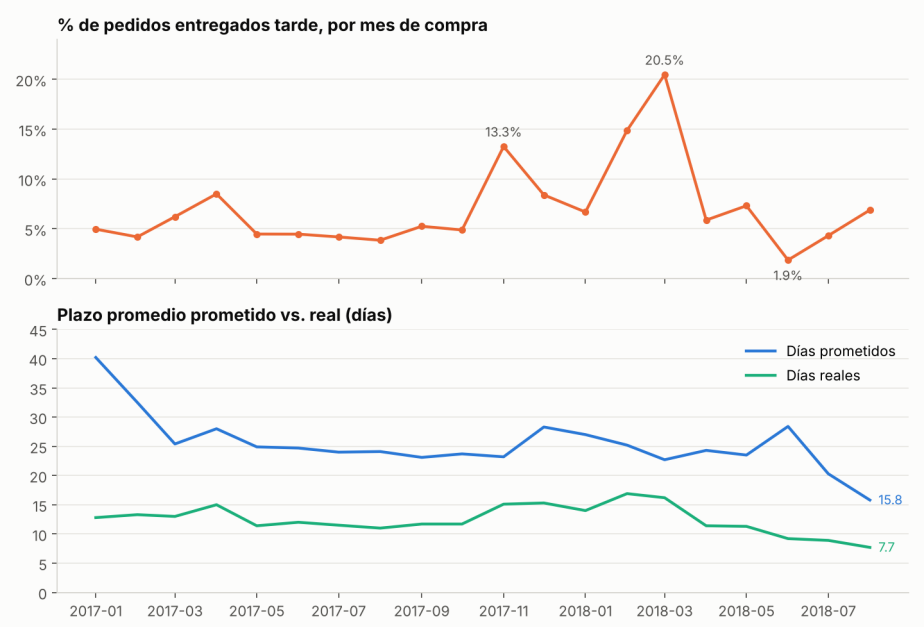


Figura 1. El retraso tuvo picos en noviembre de 2017 y en febrero-marzo de 2018. A mediados de 2018 Olist acortó sus promesas de ~24 a ~16 días: el modelo se evalúa en un régimen distinto al de entrenamiento.

- **Pocos días de retraso ya pesan.** Las reseñas negativas pasan de ~9% en pedidos puntuales a 32% con 1-3 días de retraso, y a más de 67% con 4 o más días.

- **La ruta importa más que la distancia.** El retraso sube de 5.3% en entregas de menos de 100 km a 13.9% en las de más de 2,000 km. Pero Río de Janeiro, a 490 km en promedio de sus vendedores, tiene 14% de retraso: casi el triple que São Paulo.
- **Los retrasos están concentrados.** El 3.4% de los vendedores acumula la mitad de los pedidos tardíos.

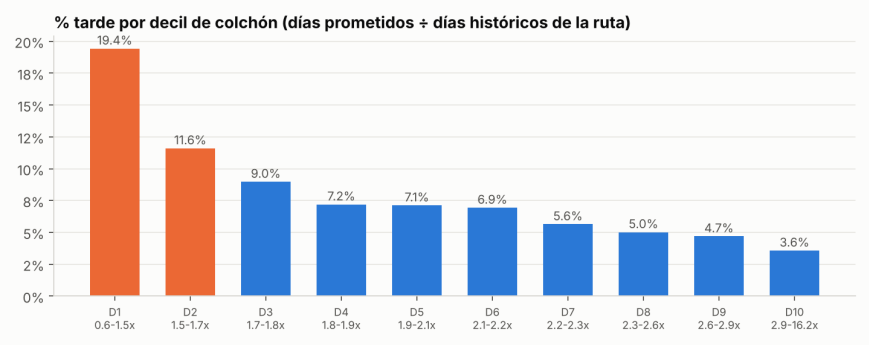


Figura 2. % de pedidos tardíos por decil del colchón del plazo (periodo de entrenamiento). Con el colchón más corto, 19% llega tarde; con el más amplio, menos de 4%.

4. Modelo

Protocolo.

- **Candidatos:** la regla del colchón, una regresión logística y un gradient boosting de scikit-learn, con 26 variables disponibles al momento de la compra.
- **Selección:** en un periodo de validación, ene-mar 2018.
- **Prueba:** una sola vez, en abr-ago 2018, con intervalos de confianza de 95% por bootstrap (1,000 remuestreos).
- **Estabilidad:** un backtest mes a mes, de octubre de 2017 a agosto de 2018.

Métrica principal: % de retrasos capturados al revisar el 10% de pedidos más riesgosos. Es la capacidad supuesta del equipo y responde directamente a la pregunta de negocio. La exactitud no sirve con 7.8% de positivos.

Fuga de datos. El historial de un vendedor o ruta solo incluye pedidos cuyo resultado ya se conocía al comprar: un pedido puntual se conoce al entregarse; uno tardío, al terminar su día prometido. Lo verifiqué por fuerza bruta en 500 pedidos, sin discrepancias. Los priors de suavizado y los codificadores solo usan datos anteriores al periodo evaluado. El mes de compra y los volúmenes absolutos se descartaron porque permitían memorizar la época del entrenamiento; la ventana de 90 días del historial de la ruta se eligió en validación.

Candidato	Validación: captura	Prueba: captura (IC 95%)	Prueba: AUC-PR	Prueba: AUC-ROC	Backtest: captura prom.
Regla del colchón	26.9%	29.4% (27.4–31.3)	0.133	0.718	24.7%
Regresión logística	25.4%	26.0% (24.1–28.0)	0.115	0.685	23.5%
Gradient boosting	19.5%	25.9% (24.1–27.9)	0.120	0.697	20.9%

Tabla 1. La regla gana en validación, en prueba y en el promedio del backtest. En prueba, la diferencia de captura contra la regla es de −3.4 puntos para la regresión logística (IC −5.8 a −0.8) y de −3.5 para el boosting (IC −5.8 a −1.0). La tasa base de retraso bajó de 14% en validación a 5.3% en prueba, lo que explica el menor AUC-PR.

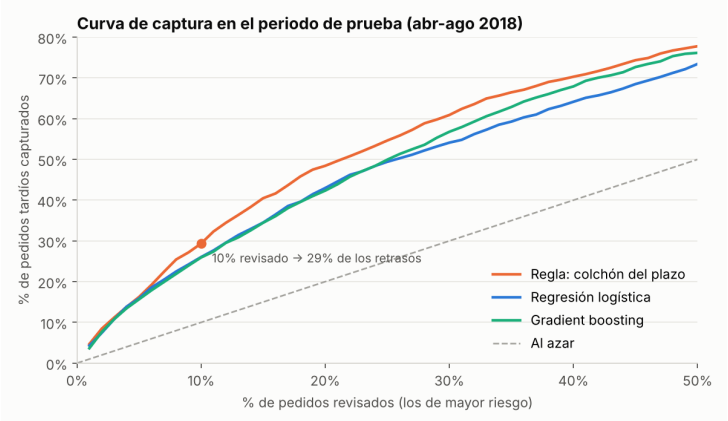


Figura 3. Curva de captura en prueba: la regla domina en casi todo el rango de pedidos revisados.

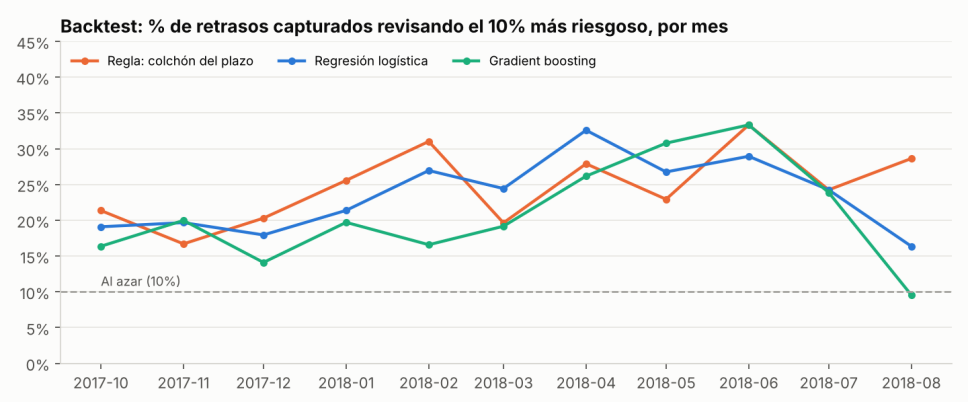


Figura 4. Backtest mensual. La regla nunca baja de 16.7%. El gradient boosting cae por debajo del azar en agosto de 2018, cuando las promesas se acortaron: aprendió patrones de una época que ya no existía.

¿Por qué gana la regla? En la importancia por permutación del boosting, el colchón del plazo pesa casi el triple que la siguiente variable. Las 25 variables restantes aportan poca información nueva, y en cambio dan al modelo margen para memorizar el pasado. Con el negocio cambiando tan rápido, una regla basada en la historia reciente de la ruta envejece mejor.

5. Recomendación

a) Alerta diaria para logística. Marcar los pedidos cuyo colchón esté por debajo del percentil 10 de los últimos 30 días. El umbral se actualiza solo y no requiere reentrenar. En prueba marcó el 13.0% de los pedidos y capturó el **32.9%** de los retrasos; el 13.5% de los marcados llegó tarde, 2.5 veces la tasa base. Un umbral fijo calibrado en validación se desajustaba y marcaba el 17.8%.

b) Colchón mínimo en la fecha prometida. No prometer menos de r veces lo que tarda la ruta. Simulación en prueba con los días reales de entrega:

Colchón mínimo (r)	Pedidos con promesa ajustada	Días extra (ajustados)	Tardíos rescatados	Reseñas negativas evitadas (est.)
1.3	21.6%	+3.6	398 (23.1%)	~85
1.5	34.3%	+4.7	607 (35.2%)	~164
1.7	47.3%	+6.0	779 (45.2%)	~236
2.0	65.9%	+8.0	982 (57.0%)	~339

Tabla 2. Periodo de prueba, abr-ago 2018: 1,724 pedidos tardíos. Las reseñas evitadas se estiman como las reseñas negativas reales de los pedidos rescatados menos las que tendrían con la tasa de un pedido puntual (9.5%).

Propongo empezar con **r = 1.3**: ajusta la promesa del 22% de los pedidos en +3.6 días y rescata el 23% de los tardíos. Conviene lanzarlo como **prueba A/B**, porque una promesa más larga puede bajar la conversión y este dataset, que solo trae compras concretadas, no permite medirlo.

6. Limitaciones

- La atribución de reseñas a los retrasos es correlacional; los pedidos tardíos y puntuales pueden diferir en otros factores.
- Los datos terminan en agosto de 2018 y reflejan el marketplace de esa época.
- La captura depende de la capacidad supuesta (10%); la curva de la Figura 3 muestra el resultado con otras capacidades.